# Een analyse van een bestaand content-based Spotify recommender system

Roos Brouwer, Sarah Kruse, Tijmen de Langen & Nina Dobbelaar

*15799972, 15396142, 15858855, 15823938*

March 20, 2026

# Contents

**1 Inleiding** **3**
1.1 Onderzoeksvraag . . . 3
1.2 Deelvragen technische analyse . . . 3

**2 Technische Analyse** **3**
2.1 Beschrijving recommender . . . 3
2.2 Analyse en experiment . . . 4
2.3 Resultaten en evaluatie . . . 4
2.3.1 Overeenkomst aanbevolen genres en ingevoerde nummers . . . 4
2.3.2 Hoe groot is de similarity tussen inputnummers en aanbevolen nummers op basis van audiofeatures? . . . 6
2.3.3 In welke mate blijven aanbevelingen binnen dezelfde muzikale clusters als de input? . . . 6

**3 Theoretische analyse** **8**
3.1 Filterbubbels . . . 8
3.2 Trade-offs: nauwkeurigheid en diversiteit . . . 8
3.3 Voordelen en nadelen van het recommender system . . . 8
3.4 Data afhankelijkheid . . . 8
3.5 Transparantie en explainability . . . 9
3.6 User wants en user needs . . . 9
3.7 Balans tussen economisch en publiek belang . . . 9
3.8 Negatieve implicaties en hun oplossing . . . 9

**4 Conclusie** **9**

# 1 Inleiding

Recommender-systemen spelen een grote rol op platforms zoals Spotify, omdat zij bepalen welke muziek gebruikers te zien en te horen krijgen. Deze systemen zijn niet alleen technisch belangrijk, maar beïnvloeden ook in hoeverre gebruikers nieuwe muziek ontdekken of juist vooral aanbevelingen krijgen die aansluiten bij hun bestaande voorkeuren.

In dit onderzoek staat een content-based Spotify-recommender gemaakt door unkletam (n.d.) centraal. Dit type systeem doet aanbevelingen op basis van kenmerken van nummers, zoals danceability, energy, valence en tempo. Een voordeel van deze aanpak is dat aanbevelingen goed aansluiten bij de input van de gebruiker. Tegelijkertijd bestaat het risico dat het systeem vooral "more of the same" aanbeveelt en daardoor weinig divers is.

In deze analyse onderzoeken wij daarom in hoeverre de aanbevelingen aansluiten bij het genre en de audiofeatures van de inputnummers, en in welke mate het systeem bestaande muzikale patronen reproduceert. Hiervoor zijn synthetische gebruikers gegenereerd, waarna per gebruiker aanbevelingen zijn berekend en geanalyseerd op genre-overlap en similarity.

De centrale onderzoeksvraag luidt:

## 1.1 Onderzoeksvraag

*"In hoeverre genereert deze content-based Spotify-recommender aanbevelingen die aansluiten bij het genre en de audiofeatures van de inputnummers, en welke gevolgen heeft dit voor de diversiteit, transparantie en mogelijke bias van het systeem?"*

Daarnaast zullen wij binnen de technische analyse nog een paar deelvragen beantwoorden, deze luiden als volgt:

## 1.2 Deelvragen technische analyse

- In welke mate komen aanbevolen nummers overeen met het genre van de inputnummers?
- Hoe groot is de similarity tussen inputnummers en aanbevolen nummers op basis van audiofeatures?
- In welke mate blijven aanbevelingen binnen dezelfde muzikale clusters of patronen als de input?

# 2 Technische Analyse

## 2.1 Beschrijving recommender

In deze analyse staat niet alleen de werking van het oorspronkelijke recommender-systeem centraal, maar vooral de manier waarop wij het systeem experimenteel hebben onderzocht. Het originele systeem is een content-based recommender voor Spotify. Aanbevelingen worden daarbij gebaseerd op numerieke audio- en metadatafeatures van nummers, zoals `valence`, `acousticness`, `danceability`, `energy`, `loudness`, `popularity` en `tempo`. Op basis van deze kenmerken worden nummers als vectoren gerepresenteerd en met elkaar vergeleken.

De kern van de recommendatiefunctie bestaat uit drie stappen. Eerst worden inputnummers gekoppeld aan bestaande songdata via `get_song_data()`. In de originele implementatie werd eerst gezocht naar een exacte match in de lokale dataset, waarna bij mislukking een fallback naar de Spotify API plaatsvond via `find_song()`. In onze eigen analyse hebben wij deze API-fallback verwijderd, omdat wij geen toegang hadden tot de Spotify API. In plaats daarvan hebben wij uitsluitend een lokale lookup gebruikt: eerst op genormaliseerde songtitel en jaartal, en als fallback op alleen de songtitel. Dit maakt het systeem volledig reproduceerbaar met lokale data, maar verhoogt ook de kans op verkeerde matches wanneer meerdere nummers dezelfde titel delen.

Vervolgens maakt `get_mean_vector()` een gebruikersprofiel aan door van de inputnummers een gemiddelde featurevector te nemen. Deze vector is gebaseerd op twaalf numerieke kenmerken: `valence`, `acousticness`, `danceability`, `duration_ms`, `energy`, `explicit`, `instrumentalness`, `liveness`, `loudness`, `popularity`, `speechiness` en `tempo`. Daarna gebruikt `recommend_songs()` een `StandardScaler` om zowel de dataset als het inputprofiel te schalen en berekent het systeem met cosine distance de afstand tussen het gemiddelde gebruikersprofiel en alle nummers in de dataset. De songs met de kleinste afstand worden vervolgens als aanbeveling teruggegeven. Hoewel clustering in andere delen van het oorspronkelijke project een rol speelt, is de uiteindelijke recommendatielogica in de door ons onderzochte implementatie dus vooral gebaseerd op directe feature similarity over de volledige dataset.

## 2.2 Analyse en experiment

Onze eigen technische analyse richt zich echter niet alleen op deze interne werking, maar vooral op het gedrag van het systeem op grotere schaal. Om dit te onderzoeken hebben wij vijfhonderd gebruikers gegenereerd. Elke gebruiker kreeg tien willekeurig gekozen nummers uit hetzelfde genre uit de lokale dataset als input waarna de gebruikers dertig aanbevolen nummers als output kregen. Deze randomisatie maakt het mogelijk om het systeem systematisch te testen zonder echte gebruikersdata of luistergeschiedenis. Voor iedere gebruiker zijn er vervolgens aanbevelingen gegenereerd met de (licht aangepaste) recommender van unkletam (n.d.).

Om de output te kunnen evalueren, hebben wij daarnaast een genrevariabele geconstrueerd. Omdat de songdataset zelf geen directe, eenduidige genrekolom bevatte op trackniveau, hebben wij genres gekoppeld via artiestinformatie. Daarbij is per nummer gekeken naar de eerste genoemde artiest, waarna op basis van aanvullende data is vastgesteld binnen welke genres deze artiest voorkomt. Dit genrelabel functioneert in onze analyse als een proxy voor muzikale categorie. Deze aanpak is niet perfect, omdat artiesten in meerdere genres kunnen voorkomen en trackniveau en artiestniveau niet volledig samenvallen, maar het biedt wel een werkbare manier om systematisch patronen in de aanbevelingen te analyseren. Vervolgens zijn op basis van het genre gebruikers gegenereerd die in één bepaald genre luisteren.

Op basis van deze opzet onderzoeken wij in hoeverre het systeem aanbevelingen blijft doen binnen hetzelfde genre als de input. We analyseren of aanbevolen nummers genres delen met de inputnummers van een gebruiker, en in welke mate het systeem dus geneigd is om binnen bestaande muzikale patronen te blijven. Daarmee meten wij niet of de aanbevelingen subjectief "goed" zijn, maar wel of het systeem genre-consistente output produceert. Dit is relevant, omdat een content-based recommender door zijn ontwerp het risico loopt vooral "more of the same" te genereren. Als aanbevelingen sterk binnen hetzelfde genre blijven, wijst dit op een beperkte mate van exploratie en diversiteit. Andersom kan een lagere genre-overlap erop wijzen dat het systeem makkelijker buiten de directe inputcategorie treedt.

Een sterk punt van onze analysemethode is dat zij het gedrag van de recommender empirisch zichtbaar maakt op een groot aantal gesimuleerde gebruikersprofielen. Tegelijkertijd kent ook deze methode beperkingen. De synthetische gebruikers representeren geen echte voorkeuren, maar willekeurige combinaties van songs. Daarnaast is genre hier slechts een benadering van muzikale samenhang. Onze analyse moet daarom niet gelezen worden als een directe meting van gebruikerstevredenheid, maar als een systematische test van de mate waarin het systeem genregebonden en potentieel weinig divers aanbeveelt.

## 2.3 Resultaten en evaluatie

### 2.3.1 Overeenkomst aanbevolen genres en ingevoerde nummers

Voor de eerste deelvraag wordt onderzocht in welke mate de aanbevolen nummers overeenkomen met het genre van de inputnummers. Hiervoor is gebruikgemaakt van het eerder beschreven experiment

met gesimuleerde gebruikersprofielen, waarbij voor elke gebruiker aanbevelingen zijn gegenereerd op basis van tien willekeurige inputnummers uit hetzelfde genre. Deze opzet maakt het mogelijk om systematisch te analyseren in hoeverre het recommender-systeem geneigd is om binnen bestaande muzikale categorieën te blijven bij het doen van suggesties.

Om de mate van genre-overeenkomst te kunnen kwantificeren, is voor elke gebruiker berekend welk percentage van de aanbevolen nummers binnen hetzelfde genre valt als de inputnummers. Deze maat geeft direct inzicht in hoe vaak het systeem volledig genre-consistente aanbevelingen doet en in welke gevallen het ook nummers uit andere genres voorstelt. Figuur 1 toont de verdeling van deze percentages over alle gesimuleerde gebruikers.

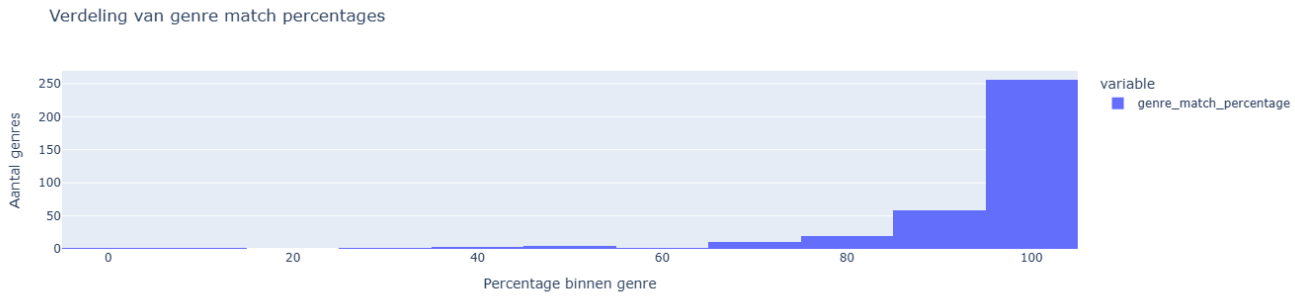


**Figure 1:** Verdeling van het percentage aanbevelingen da binnen het inputgenre valt per gesimuleerde gebruiker

De figuur laat zien dat veel gebruikers voornamelijk genre-consistente aanbevelingen ontvangen, maar dat bij sommige gebruikers ook een deel van de aanbevelingen uit andere genres komt. Dit laat zien dat het systeem overwegend binnen het inputgenre blijft, maar in beperkte mate ook nieuwe genres introduceert.

Daarnaast is gekeken of de populariteit van nummers een rol speelt bij genre-overeenkomst. Hiervoor is een variabele *genre_match* gemaakt: deze is 1 als een aanbevolen nummer binnen hetzelfde genre valt als de inputnummers, en 0 als dat niet zo is. Door deze variabele te correleren met de populariteit van de nummers blijkt dat er vrijwel geen verband is (tabel 1). Met andere woorden, nummers binnen het inputgenre zijn gemiddeld niet populairder of minder populair dan nummers uit andere genres. De correlatieanalyse tussen *genre_match* en *popularity* liet een zeer zwakke negatieve samenhang zien. Dit resultaat is weergegeven in tabel 1.

| | **genre_match** | **popularity** |
|---|---|---|
| **genre_match** | 1.000000 | -0.088877 |
| **popularity** | -0.088877 | 1.000000 |

**Table 1:** Correlatiematrix van genre_match en popularity

Samengevat genereert het systeem vooral nummers die qua genre aansluiten bij de inputnummers, maar introduceert het in beperkte mate ook nummers uit andere genres. Dit zorgt voor een balans tussen relevante aanbevelingen en beperkte exploratie, en bevestigt dat een content-based recommender effectief werkt voor het vinden van vergelijkbare muziek, terwijl de diversiteit van de aanbevelingen relatief beperkt blijft.

### 2.3.2 Hoe groot is de similarity tussen inputnummers en aanbevolen nummers op basis van audiofeatures?

Om te onderzoeken hoe goed de aanbevolen nummers overeenkomen met de input-nummers, is de cosine similarity berekend op basis van de audiofeatures valence, acousticness, danceability, energy, instrumentalness, liveness, loudness, speechiness en tempo. Voor iedere gebruiker is een similarity matrix opgesteld waarin de rijen de input-nummers en de kolommen de aanbevolen nummers vertegenwoordigen. Het gemiddelde van deze matrix per gebruiker is genomen en over alle gebruikers resulteert dit in een algemene audio-similarity van 0.902, wat wijst op een hoge overeenstemming tussen input- en aanbevolen nummers.

Deze hoge score betekent dat de aanbevolen nummers muzikaal sterk lijken op de nummers die de gebruiker al kent. Bijvoorbeeld, als een gebruiker nummers zoals "U2 - With or Without You" en "Coldplay - Clocks" als input heeft, kunnen aanbevolen nummers verschijnen zoals "Keane - Somewhere Only We Know" of "Snow Patrol - Chasing Cars", die zowel qua emotionele toon als energie en andere muzikale kenmerken goed aansluiten.

Tegelijkertijd suggereert deze hoge similarity een mogelijke "more-of-the-same" bias, waarbij het systeem vooral nummers aanbeveelt die lijken op eerdere voorkeuren. Dit versterkt de coherentie en relevantie van de aanbevelingen, maar kan de ontdekking van nieuwe of minder bekende nummers beperken.

### 2.3.3 In welke mate blijven aanbevelingen binnen dezelfde muzikale clusters als de input?

Binnen het onderzoek zijn de muzikale clusters gedefinieerd op basis van audiofeatures. Deze clusters zijn door unkletam (n.d.) zichtbaar gemaakt met clustering en t-SNE-visualisaties. Wanneer aanbevelingen in dezelfde cluster blijven als de inputnummers, wijst dit erop dat het systeem bestaande muzikale patronen reproduceert. Voor de vijfhonderd gebruikers die zijn gegenereerd en zijn ingevoerd bij de recommender, is bekeken in hoeverre de aanbevolen nummers in hetzelfde cluster blijven. In Figuur 1 is te zien dat de de aanbevelingen in sterke mate binnen hetzelfde cluster blijven als de input. De verdeling is rechts scheef en laat zien dat voor het grootste deel van de gebruikers het merendeel van de aanbevolen nummers binnen hetzelfde genre valt als de input. De resultaten suggereren dat het systeem dicht bij de muzikale voorkeuren van de gebruikers blijven. Hoewel deze maat gebaseerd is op genre-overlap en niet direct op clusterlabels, biedt het een sterk inzicht dat de recommender meestal binnen dezelfde muzikale genres blijft als de input. De uitkomst laat zien dat het systeem optimaliseert op overeenkomst, maar minder bijdraagt aan diversiteit binnen de aanbevolen nummers. Een voorbeeld van een gebruiker met haar aanbevolen nummers is te zien in Figuur 2, hier is te zien dat de aanbevolen nummers bijna allemaal in hetzelfde cluster vallen. De user is gemarkeerd in het blauw (dit is de mean vector van de inputnummers) en de aanbevolen nummers zijn de rode bolletjes. Dit zijn er maar drie, omdat er dus veel in hetzelfde genre zijn gevallen. Van dezelfde gebruiker is in Figuur 3 de similarity tussen de inputnummers en de aanbevolen nummers geplot in een heatmap om nog duidelijk te laten zien dat de similarity tussen deze nummers bij het merendeel van de aanbevolen nummers heel hoog is. Dit resultaat is logisch, omdat de recommender aanbevelingen selecteert op basis van overeenkomst in audiofeatures. Wanneer nummers sterk op elkaar lijken in termen van bijvoorbeeld energy, danceability, valence en tempo, is de kans groot dat zij ook binnen hetzelfde genre of muzikale patroon vallen. De hoge similarity tussen inputnummers en aanbevolen nummers helpt dus verklaren waarom de genre-overlap in veel gevallen eveneens hoog is.

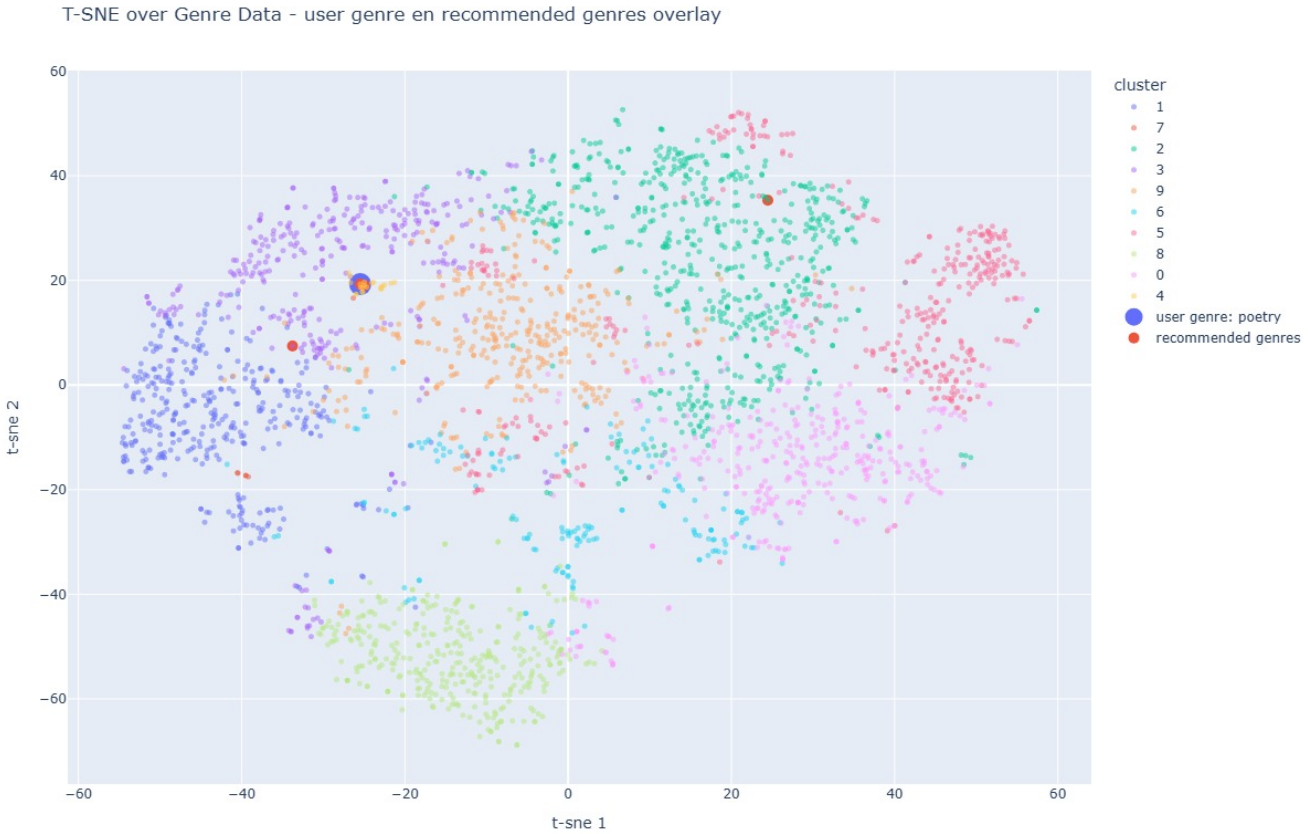


**Figure 2:** T-SNE: user 347 genre (poetry) en genres van recommended songs

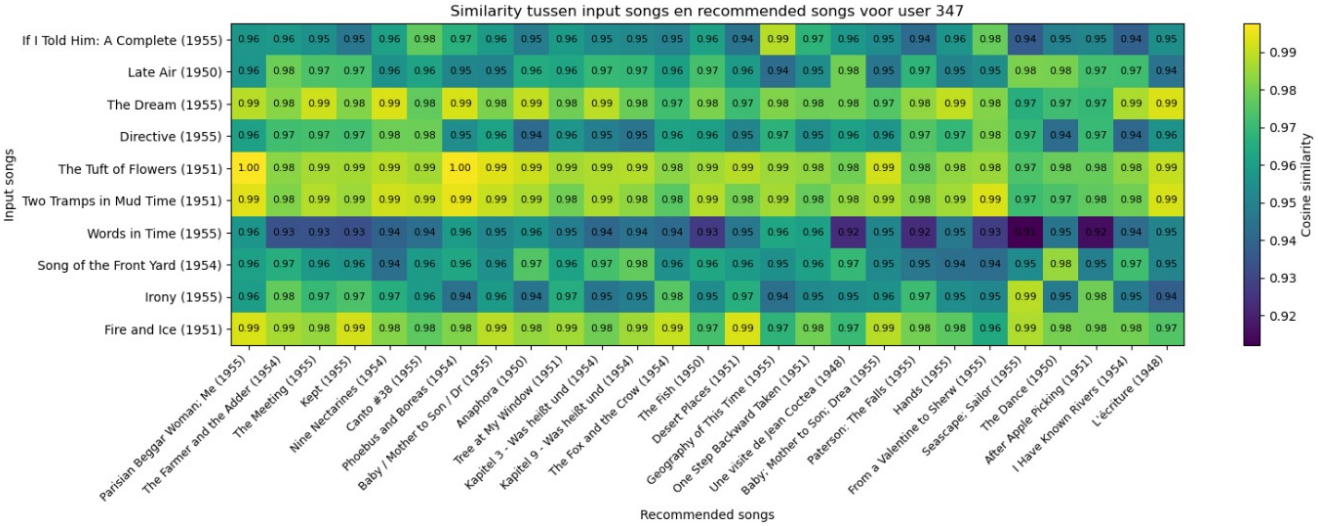


**Figure 3:** Similarity tussen input songs en recommended songs voor user 347 (poetry)

# 3 Theoretische analyse

Een belangrijk inzicht uit onze technische analyse over recommender systems is dat content-based systemen sterk geneigd zijn om aanbevelingen te geven die lijken op eerder gedrag van de gebruiker. Dit komt overeen met de literatuur, het wordt ook wel aangeduid als het "more of the same" principe (Ricci et al., 2010). In dit onderzoek komt dit dan ook duidelijk naar voren, de aanbevolen nummers blijven in hoge mate binnen hetzelfde genre en vertonen een hoge overeenkomst in audiokenmerken.

## 3.1 Filterbubbels

Dit fenomeen kan duidelijk worden verklaard vanuit het concept van de filterbubbel (Pariser, 2011). Een filterbubbel is een bias die ontstaat wanneer algoritmes gebruikers voornamelijk content tonen die aansluit bij hun bestaande keuzes. Hierdoor is blootstelling aan nieuwe of afwijkende informatie beperkt. In dit onderzoek zorgt dat er voor dat gebruikers moeilijk buiten hun bestaande muziekgenre komen. Ook de resultaten ondersteunen dit, doordat het recommender system ook werkt op basis van de gelijkenis in audiokenmerken, worden er nummers aanbevolen die sterk lijken op eerdere keuzes. Dit leidt tot een hoge nauwkeurigheid maar een lage diversiteit, volgens de literatuur is dit ook een bekende trade-off binnen recommender systems (Nguyen et al., 2014).

## 3.2 Trade-offs: nauwkeurigheid en diversiteit

Een centrale ontwerpkeuze in recommender systems is de balans tussen verschillende kwaliteitscriteria. Hieronder vallen ook de relevantie en diversiteit (Ricci et al., 2010). In ons systeem ligt de nadruk duidelijk op de nauwkeurigheid, de cosine similarity van gemiddeld 0,902 laat zien dat aanbevelingen zeer goed aansluiten. Dat de nauwkeurigheid zo hoog is brengt ook nadelen met zich mee. In dit systeem is namelijk weinig diversiteit, wat zorgt voor geen variatie in genres. Ook is er een beperkte kans op serendipiteit, er zullen nauwelijks onverwachte ontdekkingen worden gedaan. het systeem optimaliseert voorspelbaarheid ten koste van ontdekking.

## 3.3 Voordelen en nadelen van het recommender system

Het onderzochte recommender system bevoordeelt vooral gebruikers met duidelijke en consistente muziekvoorkeuren. Doordat het systeem aanbevelingen baseert op hoge overeenkomst in audiofeatures, krijgen deze gebruikers relevante en herkenbare suggesties. Dit sluit aan bij het doel van veel recommender systems om maximale gebruikers satisfactie en engagement te realiseren. Echter worden hierdoor gebruikers die juist nieuwe muziek willen ontdekken benadeeld. Zij krijgen weinig verrassende of afwijkende aanbevelingen, omdat het systeem gericht is op het reproduceren van bestaande voorkeuren. Daarnaast zijn ook minder bekende of atypische artiesten in het nadeel. Vanuit het perspectief van data- en exposure bias worden vooral artiesten en genres die al goed vertegenwoordigd zijn in de dataset vaker aanbevolen. Dit leidt tot een ongelijke verdeling van zichtbaarheid. Starke et al. (2022) formuleert dat eerlijkheid van een recommender system onder andere gemeten kan worden door te kijken of uitkomsten eerlijk worden verdeeld over gebruikers. Bij het onderzochte recommender system heeft niet elke gebruiker dezelfde kans om zijn voorkeuren te ontvangen, dit maakt de distributive fairness van het systeem beperkt, omdat bepaalde voorkeuren en genres structureel worden bevoordeeld boven andere.

## 3.4 Data afhankelijkheid

Daarnaast speelt ook data bias een rol binnen dit systeem. Het is namelijk volledig afhankelijk van de gebruikte dataset en de gekozen kenmerken hierbij. Dit betekent dan ook dat muziek wordt gereduceerd tot meetbare eigenschappen en de culturele of andere aspecten van de muziek buiten beschouwing blijven. Dit zorgt voor een representation bias (Barocas et al., 2019). Niet alle aspecten

van muziek worden eerlijk of volledig meegenomen in de aanbevelingen. Bovendien is er gebruik gemaakt van genrelabels gebaseerd op de artiest informatie. Dit introduceert een extra onzekerheid, omdat artiesten meerdere genres kunnen hebben.

### 3.5 Transparantie en explainability

Een voordeel van content-based systemen is dat ze relatief transparant zijn. In principe kan aan iedereen worden uitgelegd waarom een nummer wordt aanbevolen. Toch is deze uitleg niet volledig, gebruiker zien meestal niet welke kenmerken worden gebruikt en het gemiddelde profiel is ook niet inzichtelijk voor gebruikers. Hierdoor is er toch nog wel een kloof tussen de technische werking en de gebruikerservaring. Volgens de literatuur is dit juist niet wat er moet zijn, explainability is belangrijk voor de vertrouwen en begrip bij gebruikers (Barocas et al., 2019).

### 3.6 User wants en user needs

Verder is er een belangrijk verschil tussen wat de gebruiker echt wilt en wat ze nodig hebben. Recommender systems spelen vaak in op directe voorkeuren, zoals het blijven luisteren naar hetzelfde genre. Toch is het vaak dat gebruikers ook behoefte hebben aan variatie en ontdekking. Dit systeem richt zich voornamelijk op de korte termijn, en minder op de lange termijn gebruikerservaring. Er is weinig ruimte voor muzikale ontwikkeling of verbreding van smaak, gebruikers blijven vastzitten in wat ze op dat moment leuk vinden. Dit sluit aan bij kritiek op moderne platforms, waarbij algoritmes alles doen om betrokkenheid te maximaliseren. Dit gaat ten koste van het welzijn of ontwikkeling van de gebruiker (Pariser, 2011).

### 3.7 Balans tussen economisch en publiek belang

Economisch en publiek belang staan verbonden maar gaan niet altijd samen. De taak van een recommender vanuit een economisch perspectief is om de gebruiker zo lang mogelijk betrokken te houden, bijvoorbeeld door persoonlijke aanbevelingen. Vanuit een publiek belang gezien spelen naast persoonlijke aanbevelingen ook waarden zoals diversiteit, ontdekking en autonomie een rol. Een recommender system zal altijd ontwerpkeuzes bevatten die bepaalde waarden prioriteren, dit is afhankelijk van de maker en het doel. In dit geval prioriteert het systeem nauwkeurigheid en gebruikersbetrokkenheid boven diversiteit en exploratie. Hoewel persoonlijke aanbevelingen ook onder publiek belang vallen, zou er dus gesteld kunnen worden dat dit recommender system vanuit een meer economisch oogpunt ontworpen is.

### 3.8 Negatieve implicaties en hun oplossing

Het recommender system kan verschillende negatieve implicaties hebben, zoals het versterken van filterbubbels, het beperken van diversiteit en het ongelijk verdelen van zichtbaarheid tussen artiesten en genres. Daarnaast wordt de autonomie van gebruikers beperkt en is er sprake van representation bias doordat muziek wordt gereduceerd tot meetbare audiofeatures. Om deze negatieve implicaties tegen te gaan, zou er meer diversiteit toegevoegd moeten worden aan het algoritme, bijvoorbeeld door een deel van de aanbevelingen te reserveren voor minder vergelijkbare nummers. Een andere toepassing om meer diversiteit te stimuleren is bijvoorbeeld de discover weekly van Spotify, waarbij gebruikers elke week minder voor de hand liggende nummers aangeboden krijgen.

## 4 Conclusie

In dit onderzoek is onderzocht in hoeverre deze content-based Spotify-recommender aanbevelingen genereert die aansluiten bij het genre en de audiofeatures van de inputnummers, en welke gevolgen

dit heeft voor de diversiteit, transparantie en mogelijke bias van het systeem. De resultaten laten zien dat het systeem in hoge mate relevante en consistente aanbevelingen produceert. De gemiddelde cosine similarity van 0.902 en de hoge genre-overlap wijzen erop dat aanbevolen nummers meestal sterk lijken op de input, zowel qua audiofeatures als qua muzikaal patroon.

Tegelijkertijd blijkt dat deze nauwkeurigheid ten koste gaat van diversiteit. Doordat het systeem optimaliseert op overeenkomst in kenmerken zoals valence, danceability, energy en tempo, blijven aanbevelingen vaak binnen hetzelfde genre of dezelfde muzikale regio. Dit versterkt bestaande voorkeuren en vergroot de kans op een "more of the same"-effect en filterbubbels.

Daarnaast laat de analyse zien dat het systeem sterk afhankelijk is van de gebruikte dataset en genrelabels, wat kan leiden tot representation bias. Hoewel het systeem relatief uitlegbaar is, blijft voor gebruikers beperkt zichtbaar waarom specifieke nummers worden aanbevolen. De conclusie is daarom dat deze recommender technisch goed werkt voor vergelijkbare aanbevelingen, maar minder geschikt is voor muzikale ontdekking en variatie.

# References


Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and machine learning: Limitations and opportunities*. MIT Press.

Nguyen, T., Hui, P.-M., Harper, F., & Terveen, L. (2014). Exploring the filter bubble: The effect of using recommender systems on content diversity. *WWW 2014 - Proceedings of the 23rd International Conference on World Wide Web*, 677–686. https://doi.org/10.1145/2566486.2568012

Pariser, E. (2011). *The filter bubble: What the internet is hiding from you*. Penguin Press.

Ricci, F., Rokach, L., & Shapira, B. (2010, October). Recommender systems handbook. https://doi.org/10.1007/978-0-387-85820-3_1

Starke, C., Baleis, J., Keller, B., & Marcinkowski, F. (2022). Fairness perceptions of algorithmic decision-making: A systematic review of the empirical literature. *Big Data Society*, *9*. https://doi.org/10.1177/20539517221115189

unkletam. (n.d.). Spotify-recommendation-system [GitHub repository, accessed 2026-03-14].